

■ Relatório Técnico de Machine Learning — Visão Computacional

Projeto: Breast Ultrasound Images (BUSI) | Aluno: Gustavo Luis dos Santos

■ ACESSO AO REPOSITÓRIO & RECURSOS:

- **GitHub do Projeto:** <https://github.com/gustavobhm/fiap-tech-challenge-fase1>
- **Notebook Processado:** notebooks/02_visao_computacional_cnn_busi_v9.ipynb
- **Vídeo de Demonstração:** [COLOQUE SEU LINK DO YOUTUBE AQUI](#)

Introdução: Escopo e Objetivo do Relatório

Este relatório técnico documenta o pipeline completo de Visão Computacional e Deep Learning desenvolvido para o diagnóstico automatizado de lesões mamárias via ultrassonografia (Dataset *Breast Ultrasound Images - BUSI*). O objetivo é demonstrar a aplicação de Redes Neurais Convolucionais (CNNs) atuando como um Sistema de Apoio à Decisão Clínica (CDSS). O documento reflete todo o ciclo de vida dos dados, focando em:

- **Alta Sensibilidade Diagnóstica:** Priorização da métrica *Recall* (Sensibilidade) para minimização de Falsos Negativos na detecção de câncer de mama.
- **Explicabilidade e Auditoria Visual:** Aplicação de mapas de ativação (Grad-CAM) para assegurar que a IA fundamenta as previsões na morfologia das massas nodulares.
- **Aplicabilidade Clínica:** Discussão sobre como a IA integra-se à rotina hospitalar para triagem rápida e dupla checagem.

Step 1: Preparação do Ambiente

- **O que foi feito:** Instalamos e carregamos as ferramentas (bibliotecas) essenciais para o projeto. As principais são:
 - **TensorFlow/Keras:** O *framework* fundamental para a construção, treinamento e avaliação da Inteligência Artificial, especialmente para Redes Neurais Convolucionais.
 - **OpenCV (cv2):** Uma biblioteca robusta para processamento de imagens, utilizada para manipulação, redimensionamento e pré-processamento das imagens de ultrassom.
 - **Matplotlib e Seaborn:** Ferramentas poderosas para a visualização de dados e gráficos, que nos permitem analisar o desempenho do modelo e o comportamento dos dados.
- **Por que isso é importante?** A configuração de reprodutibilidade (SEED = 42) é crucial para garantir que os resultados obtidos neste notebook, como as métricas de acurácia e a divisão dos dados, sejam exatamente os mesmos em qualquer ambiente ou execução futura. Isso assegura a validade científica e a auditabilidade do projeto.
- **Conclusão:** O ambiente de desenvolvimento está configurado, as dependências instaladas e a placa de vídeo (GPU) detectada, preparando o terreno para as próximas etapas do projeto.

Step 2: Obtenção das Imagens Médicas

- **O que foi feito:** Baixamos o banco de dados oficial **BUSI** (Breast Ultrasound Images) diretamente do repositório Kaggle via código em tempo de execução. Este dataset é fundamental para o desenvolvimento de sistemas de diagnóstico assistido por computador na detecção precoce do câncer de mama.
- **O que este banco contém?** Ele reúne **780 exames reais de ultrassom de mama**, categorizados cuidadosamente por especialistas em três diagnósticos clinicamente relevantes:
 - **Benigno:** Tumores não cancerosos que geralmente não representam risco imediato à saúde.
 - **Maligno:** Lesões cancerosas que requerem intervenção médica urgente.
 - **Normal:** Tecido mamário saudável, sem a presença de lesões ou anomalias.
- **Por que é importante?** A distinção precisa entre essas categorias é crucial para o planejamento do tratamento e para evitar biópsias desnecessárias, melhorando a eficiência e a segurança do diagnóstico.
- **Conclusão:** As imagens brutas foram baixadas e o caminho de seus arquivos está salvo na memória, prontas para a fase de pré-processamento e organização.


Step 3: Organização e Divisão dos Dados

- **O que foi feito:** O dataset original continha tanto as imagens de ultrassom brutas quanto suas respectivas máscaras de segmentação. Para este projeto de classificação, filtramos o acervo para utilizar **apenas as imagens brutas**, descartando aquelas com o sufixo '_mask' no nome do arquivo. O acervo total de **780 exames** foi dividido de forma estratificada para assegurar a representatividade das classes.
- **Distribuição e Estratificação:** Reservou-se **624 imagens (80%) para Treino** e **156 imagens (20%) para Validação/Teste**. A **divisão estratificada** é crucial em datasets desbalanceados (como este, com diferentes quantidades de exemplos para 'benigno', 'maligno' e 'normal'), pois garante que cada subconjunto (treino e validação/teste) mantenha a mesma proporção de cada classe encontrada no dataset original. Isso evita que o modelo seja treinado ou avaliado com um viés de representação.
- **Conclusão:** A filtragem garantiu que estamos trabalhando apenas com dados de imagem relevantes para a classificação, e a divisão estratificada assegurou que o modelo será treinado e avaliado com uma representação fiel da distribuição real dos diagnósticos, promovendo um aprendizado mais robusto e uma avaliação mais justa.


Exemplo: Benign



Exemplo: Malignant



Exemplo: Normal



Step 4: Pré-processamento e Aumento de Dados



- **O que foi feito:** Todas as imagens foram padronizadas para uma resolução de entrada de **224x224 pixels**, essencial para a arquitetura da rede neural, e seus valores de pixel foram **normalizados de 0-255 para 0-1** (rescale=1./255). Isso acelera a convergência do treinamento e melhora a estabilidade numérica.
- **Data Augmentation para Treino:** Aplicou-se um conjunto de **transformações geométricas e de cor probabilísticas** exclusivamente ao conjunto de treino (624 amostras) para simular variações do mundo real e aumentar a robustez do modelo. As transformações incluem:
 - rotation_range=15: Rotações aleatórias de até 15 graus.
 - width_shift_range=0.1, height_shift_range=0.1: Deslocamentos horizontais e verticais de até 10% da largura/altura da imagem.
 - zoom_range=0.1: Aplicação de zoom aleatório de até 10%.
 - horizontal_flip=True: Espelhamento horizontal das imagens.
 - fill_mode='nearest': Estratégia para preencher pixels gerados pelas transformações.
- **Pré-processamento para Validação/Teste:** As imagens destes conjuntos foram **apenas normalizadas** (rescale=1./255), sem aplicação de aumento de dados, para que a avaliação do modelo ocorra em dados representativos e não alterados.
- **Conclusão:** O gerador de imagens com *Data Augmentation* expande a variedade espacial e o tamanho efetivo do dataset de treinamento, mitigando significativamente os riscos de *overfitting* e melhorando a capacidade de generalização do modelo a novas imagens de ultrassom.

Step 5: Aprendizado por Transferência (Transfer Learning / MobileNetV2)

- **Arquitetura Base e Transfer Learning:** Optou-se por utilizar o modelo **MobileNetV2**, uma rede neural convolucional otimizada para dispositivos móveis e aplicações de visão computacional com recursos limitados. Foi escolhida especificamente por sua eficiência e por já ter sido pré-treinada no vasto dataset ImageNet, aprendendo a reconhecer características visuais genéricas. Ao congelar (trainable=False) suas camadas convolucionais (base_model.trainable = False), aproveitamos esse conhecimento pré-existente para extrair características relevantes das imagens de ultrassom, sem a necessidade de treinar milhões de parâmetros do zero.
- **Topologia Customizada (Cabeça de Classificação):** Sobre a base congelada da MobileNetV2, adicionou-se uma nova cabeça de classificação, adaptada para o problema específico de diagnóstico de ultrassom de mama. Esta cabeça consiste em:
 - Uma camada GlobalAveragePooling2D: Reduz as dimensões espaciais do mapa de características, mantendo a informação mais saliente.
 - Uma camada Dropout(0.5): Desativa aleatoriamente 50% dos neurônios durante o treinamento, uma técnica de regularização vital para prevenir o *overfitting*, especialmente em datasets médicos com tamanho limitado.
 - Uma camada Dense final com ativação Softmax: Esta camada produz as probabilidades para as **3 classes** de diagnóstico (benigno, maligno, normal), fornecendo a saída final do modelo.
- **Conclusão:** A estratégia de Transfer Learning com MobileNetV2 permite um treinamento mais rápido e eficiente em acervos médicos de porte reduzido, aproveitando o poder de representação de características de uma rede pré-treinada e otimizando a capacidade de generalização do modelo, minimizando o risco de sobreajuste aos dados específicos de treinamento.

Step 6: Treinamento e Curvas de Aprendizado

- **O que os gráficos mostram:** A rede foi treinada por **20 épocas**. Utilizamos mecanismos de *callbacks* para otimizar e proteger o treinamento:
 - **EarlyStopping:** Interrompeu o treinamento automaticamente ao detectar que a 'loss' (erro) no conjunto de validação não melhorava por 5 épocas consecutivas, restaurando os melhores pesos encontrados. Isso preveniu o *overfitting* precoce.
 - **ReduceLROnPlateau:** Reduziu a taxa de aprendizado do otimizador (Adam) pela metade (fator 0.5) se a 'loss' de validação estagnasse por 3 épocas. Esta técnica permite que o modelo faça ajustes mais finos nos pesos, explorando melhor o espaço de soluções.




- **Resultados Notáveis:** O modelo alcançou uma acurácia de validação máxima de **76.9%**, com uma perda (loss) mínima de **0.5657** no conjunto de validação.
- **Conclusão Técnica:** A análise das curvas de acurácia e perda (loss) entre os conjuntos de treino e validação demonstra uma boa convergência. A proximidade entre as curvas indica que o modelo está generalizando bem e que as estratégias de regularização (como o Dropout e o *Data Augmentation* aplicados no Step 4) foram eficazes em mitigar o *overfitting*. A estabilização das métricas sugere que o modelo aprendeu características relevantes sem memorizar os dados de treino.


Step 7: Explicabilidade Visual e Transparência do Modelo (Grad-CAM)

- **O que os mapas térmicos mostram:** Através da técnica **Grad-CAM (Gradient-weighted Class Activation Mapping)**, conseguimos visualizar as regiões da imagem de ultrassom que mais contribuíram para a decisão de classificação do modelo. As áreas em **vermelho/quente** indicam as zonas de maior ativação neural (alta relevância), enquanto as áreas em **azul/frio** foram consideradas menos importantes para o diagnóstico. O Grad-CAM funciona calculando o gradiente da pontuação da classe alvo em relação aos mapas de características da última camada convolucional, gerando um mapa de calor que destaca pixels cruciais.

--- Grad-CAM Exemplo 1: Lesão Maligna (Câncer) ---



--- Grad-CAM Exemplo 2: Lesão Benigna (Nódulo Não Canceroso) ---




- **Por que este gráfico em 3 colunas é vital para a Medicina?**
 1. **Coluna 1 (Imagem Real):** Exibe o ultrassom em escala de cinza conforme laudado pelo médico, servindo como base para a comparação.
 2. **Coluna 2 (Mapa de Ativação Pura - Grad-CAM):** Revela a intensidade do processamento interno do modelo, destacando as áreas focadas pela IA.
 3. **Coluna 3 (Sobreposição + Confiança):** Combina a foto real com o mapa de calor e mostra o diagnóstico predito e a taxa percentual de certeza. Esta fusão visual ajuda a criar **confiança e transparência** no diagnóstico assistido por IA.
- **Validação Clínica e Aumento da Confiança:** O Grad-CAM permite que o médico consiga confirmar visualmente que a IA está analisando as características clinicamente relevantes, como a borda, a densidade ou a forma do tumor, em vez de tomar decisões baseadas em ruídos, artefatos ou informações irrelevantes do ultrassom. Isso é fundamental para a aceitação e integração dessas tecnologias na prática clínica, garantindo que o modelo esteja "olhando" para os mesmos detalhes que um especialista humano consideraria importantes.

Step 8: Avaliação Final e Relatório de Classificação Médica

Relatório Completo de Classificação Médica por Classe:

Classe / Métrica	Precision	Recall	F1-Score	Support
benign	0.83	0.75	0.79	87
malignant	0.69	0.74	0.71	42
normal	0.70	0.85	0.77	27
accuracy	—	—	0.76	156
macro avg	0.74	0.78	0.76	156
weighted avg	0.77	0.76	0.76	156

Matriz de Confusão - MobileNetV2 (BUSI Dataset):



- Entendendo as Métricas por Classe (Relatório da Imagem):
 - Precision (Precisão):** Indica a proporção de verdadeiros positivos dentre todos os exemplos classificados como positivos. Ou seja, quando a IA diz que um exame é de determinada classe, qual a probabilidade de estar correta? Para a classe *benign*, o modelo obteve **0.83 (83%)** de precisão. Para *malignant*, **0.69 (69%)** e para *normal*, **0.70 (70%)**.
 - Recall (Sensibilidade):** Mede a capacidade da IA de encontrar **todos** os casos reais daquela classe. É crucial em diagnósticos médicos para evitar falsos negativos. O modelo encontrou **75%** de todas as lesões benignas reais e **74%** dos casos malignos reais.
 - F1-Score:** É a média harmônica ponderada entre Precisão e Recall. Ele oferece uma medida única do desempenho que leva em conta tanto os falsos positivos quanto os falsos negativos. O valor geral ponderado do modelo atingiu **0.76 (76%)**.
 - Support:** Mostra a quantidade real de exames de teste avaliados em cada grupo: **87 exames benignos, 42 malignos e 27 normais** (totalizando **156 exames** de validação).
- Acurácia Geral (Accuracy):** Representa a proporção total de predições corretas em relação ao número total de exemplos. O modelo acertou o diagnóstico correto em **76%** do total de exames no grupo de teste.
- Análise da Matriz de Confusão:** A matriz visualiza o desempenho do algoritmo, mostrando os verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos para cada classe. Por exemplo, a matriz revela a quantidade de casos malignos que foram erroneamente classificados como benignos, um erro de alto custo clínico.
- Conclusão Médica e Implicações:** O desempenho é sólido para uma primeira versão com dados limitados, mostrando grande capacidade de distinguir lesões benignas. Contudo, a precisão para a classe maligna, embora promissora, requer atenção contínua. Na prática clínica, este modelo deve atuar estritamente como um **Sistema de Suporte à Decisão Clínica (CDSS)**, fornecendo uma segunda opinião ou auxiliando na triagem, com a validação médica final sendo indispensável. É vital minimizar

falsos negativos (não detectar um câncer presente), mesmo que isso signifique aceitar alguns falsos positivos (detectar câncer onde não há), pois o custo de um diagnóstico perdido é muito maior.

Step 9: Salvamento do Modelo de Produção

- **O que foi feito:** O modelo de Visão Computacional, com sua arquitetura e todos os pesos treinados e otimizados, foi salvo no formato nativo Keras (arquivo `mobilenetv2_busi_best.keras`). Este formato é a maneira recomendada para persistir modelos no ecossistema TensorFlow/Keras, garantindo a compatibilidade e a integridade do modelo.
- **Para que serve este arquivo?** Este arquivo é a peça central para a etapa de **deploy em ambiente de produção**. Ele está completamente pronto para ser carregado e integrado em diversas plataformas, como:
 - **APIs Web:** Para desenvolver serviços de diagnóstico que recebem imagens e retornam as predições em tempo real.
 - **Sistemas de Imagem Hospitalares (PACS):** Para automatizar a triagem de exames de ultrassom.
 - **Aplicações Mobile/Edge:** Para inferência diretamente em dispositivos, potencialmente no próprio aparelho de ultrassom ou em tablets.
- **Benefícios do Salvamento:** Ao salvar o modelo, eliminamos a necessidade de retreiná-lo, o que economiza tempo e recursos computacionais. Além disso, o arquivo encapsula todo o conhecimento adquirido pela IA, permitindo que ele seja facilmente versionado, compartilhado e auditado, facilitando a manutenção e a governança do modelo em um contexto clínico real.