

■ Relatório Técnico de Machine Learning — Visão Computacional


Projeto: Breast Ultrasound Images (BUSI) | Aluno: Gustavo Luis dos Santos

■ ACESSO AO REPOSITÓRIO & RECURSOS:

- **GitHub do Projeto:** <https://github.com/gustavobhm/fiap-tech-challenge-fase1>
- **Notebook Processado:** notebooks/02_visao_computacional_cnn_busi_v9.ipynb
- **Vídeo de Demonstração:** [COLOQUE SEU LINK DO YOUTUBE AQUI](#)

1. Contexto Clínico e Discussões da Análise Exploratória (EDA)

O diagnóstico automatizado de lesões mamárias via ultrassonografia exige algoritmos capazes de lidar com artefatos visuais e ruídos característicos do exame. O Dataset oficial BUSI utilizado contém 780 imagens brutas de ecografia, estratificadas em três diagnósticos: Benigno, Maligno e Normal.



Discussão da EDA: A variabilidade na definição das bordas das lesões e o baixo contraste inerente à ultrassonografia direcionam a necessidade do uso de Redes Neurais Convolucionais (CNNs) profundas, capazes de extrair mapas de características hierárquicos, em vez de depender de métodos tradicionais de visão computacional (filtros manuais).

2. Estratégias de Pré-processamento e Aumento de Dados

Para adequação arquitetural e mitigação de overfitting, o seguinte pipeline de processamento foi estruturado:

- **Divisão Estratificada:** O acervo de 780 imagens foi segmentado em 624 imagens para Treinamento e 156 para Validação/Teste.
- **Redimensionamento e Normalização:** Todas as imagens foram ajustadas para a resolução de entrada de 224x224 pixels, normalizando os canais RGB.
- **Data Augmentation:** Visando melhorar a generalização espacial do modelo, aplicou-se transformações probabilísticas (rotações, translações, zoom e espelhamento horizontal) exclusivamente no conjunto de treino.


3. Modelos Usados e Justificativa (Transfer Learning)

Devido ao escopo reduzido de amostras médicas (780 imagens), treinar uma CNN do zero causaria severo sobreajuste. Por isso, a abordagem adotada foi o **Transfer Learning**:

- **Arquitetura MobileNetV2:** Escolhida como extrator de características por sua alta eficiência computacional (Depthwise Separable Convolutions) e pesos pré-treinados no banco ImageNet.
- **Topologia Otimizada:** As camadas convolucionais de base foram congeladas. Adicionou-se uma camada `GlobalAveragePooling2D` seguida de `Dropout` (0.5) para penalização de parâmetros complexos, culminando em uma densa de classificação com ativação Softmax para 3 classes.

4. Resultados Obtidos e Interpretação (Curvas de Treinamento)

O treinamento da MobileNetV2 utilizando as 780 imagens de ultrassom revelou insights importantes sobre o comportamento da rede. A avaliação da métrica principal baseou-se na maximização da sensibilidade (Recall).




Interpretação das Curvas:

- **Convergência Estável:** As Curvas de Loss de Treinamento e Validação decresceram juntas. A inserção do Dropout provou ser vital, garantindo que a Loss de validação estabilizasse sem decorar os dados de treino.
- **Atingindo o Platô:** As Curvas de Acurácia alcançaram a faixa de ~76%, confirmando a eficácia da extratora visual em um dataset sem máscaras de segmentação.

Relatório de Classificação e Matriz de Confusão:

Métrica	Precision	Recall	F1-Score	Amostras
Benigno	83.3%	74.7%	78.8%	87.0
Maligno	68.9%	73.8%	71.3%	42.0
Normal	69.7%	85.2%	76.7%	27.0
Média Geral / Total	74.0%	77.9%	76.3%	156




Interpretação Diagnóstica (Base de Teste: 156 amostras):

- **Performance Notável (Benignas):** O modelo exibiu altíssima consistência ao identificar nódulos benignos (Recall de 74.7%).
- **O Desafio Oncológico (Malignas):** A classe Maligna apresentou Recall de 73.8% e Precisão de 68.9%. A Matriz de Confusão demonstra 31 detecções verdadeiras de um total de 42 casos malignos.

5. Explicabilidade Visual e Diagnóstica (Grad-CAM)

Para viabilizar a auditoria clínica, aplicou-se o Gradient-weighted Class Activation Mapping (Grad-CAM). Abaixo observamos as inferências para diferentes classes de exame.



Interpretação do Grad-CAM: O mapeamento de calor garante que as decisões convolucionais do modelo foram embasadas na morfologia das massas nodulares capturadas nos filtros espaciais. A rede foca as zonas avermelhadas (alta ativação) diretamente na massa tumoral, evitando que a inferência seja tomada com base em vieses ou ruídos periféricos do aparelho ecográfico.

6. Discussão Crítica: A Inteligência de Imagem na Prática Médica

A adoção de modelos de Visão Computacional para o diagnóstico de ultrassom exige total alinhamento com os protocolos clínicos:

- **Suporte à Decisão Clínica (CDSS):** A CNN atua como um sistema de triagem primária e segunda opinião. A decisão final de laudo e eventual indicação de biópsia permanece sob responsabilidade exclusiva do radiologista/médico responsável.
- **Triagem Inteligente:** Exames de ultrassom cujos mapas do Grad-CAM apontem regiões de alta ativação suspeitas de malignidade podem ser automaticamente marcados como prioridade alta na fila do PACS hospitalar.
- **Auditoria Visual:** O mapa de calor (Grad-CAM) provê a transparência necessária para que o médico valide que o modelo não tomou decisões baseadas em ruídos do cabeçote ou sombras acústicas.

7. Exportação e Prontidão para Produção (Deploy)

A rede convolucional treinada foi exportada no formato nativo Keras no arquivo `mobilenetv2_busi_best.keras`. O modelo está pronto para empacotamento em microsserviços de inferência médica.