

■ Relatório Técnico de Machine Learning — Diagnóstico Tabular

Projeto: Breast Cancer Wisconsin | Aluno: Gustavo Luis dos Santos

■ ACESSO AO REPOSITÓRIO & RECURSOS:

- **GitHub do Projeto:** <https://github.com/gustavobhm/fiap-tech-challenge-fase1>
- **Notebook Processado:** notebooks/01_classificacao_tabular_wisconsin_V12.ipynb
- **Vídeo de Demonstração:** [COLOQUE SEU LINK DO YOUTUBE AQUI](#)

Introdução: Escopo e Objetivo do Relatório

Este relatório técnico documenta o pipeline completo de Machine Learning desenvolvido para o diagnóstico automatizado de câncer de mama (Dataset *Wisconsin Breast Cancer*). O objetivo é demonstrar a aplicação de algoritmos preditivos atuando como um Sistema de Apoio à Decisão Clínica (CDSS). O documento reflete todo o ciclo de vida dos dados, focando em:

- **Alta Precisão Diagnóstica:** Priorização da métrica *Recall* (Sensibilidade) para mitigar Falsos Negativos.
- **Transparência e Auditoria:** Uso de explicabilidade matemática (SHAP e *Feature Importance*) para fundamentar as predições.
- **Aplicabilidade Médica:** Discussão sobre como a IA integra-se à rotina hospitalar para triagem rápida e dupla checagem.


Step 1 & 2: Setup e Infraestrutura

- **Gestão de Dependências e Ciclo de Vida:** A instalação do SHAP e joblib prepara o ambiente para o ciclo completo de ML: desde a inferência até a auditoria e persistência do modelo em disco.
- **Engenharia de Ambiente:** Configuramos o kernel para silenciar *warnings* redundantes e ajustamos o nível de log do motor SHAP para ERROR. Isso otimiza a memória visual do notebook e garante que apenas inconsistências críticas sejam reportadas.
- **Arquitetura da Stack:**
 - **Processamento Matricial:** Numpy e Pandas formam a base para computação vetorial e manipulação de DataFrames médicos.
 - **Visualização Analítica:** Seaborn (estatístico) e Matplotlib (base) configurados para diagnósticos visuais precisos.
 - **Framework de Aprendizado:** Scikit-Learn provê os módulos de pré-processamento, validação cruzada e uma bateria de classificadores robustos.
- **Conclusão da Fase:** Esta fundação assegura que o experimento seja agnóstico ao hardware, garantindo resultados consistentes em qualquer ambiente Colab.

Step 3: Carga e Estrutura

- **Perfil da Base de Dados:** O dataset *Wisconsin Breast Cancer* foi carregado com **569 registros** e **30 atributos biomédicos**.
- **Engenharia de Dados e Categóricos:**
 - **Codificação Nativa:** O target foi mapeado automaticamente pelo loader do scikit-learn (0: Maligno, 1: Benigno), eliminando a necessidade de LabelEncoder manual.
 - **Ausência de Encoding de Features:** Composto 100% por **variáveis quantitativas contínuas**, preservando a dimensionalidade original sem dispersão por *One-Hot Encoding*.
- **Consistência e Qualidade:** Dataset íntegro e denso, com **zero valores nulos** (missing values), garantindo estabilidade estatística total para os modelos.
- **Balanceamento de Classe:**
 - **Benignos:** 357 amostras
 - **Malignos:** 212 amostras
- **Próximo Passo:** Proceder para a Análise Exploratória Visual e Correlação.


Step 4: Estatísticas e Matriz de Correlação



- **Análise de Correlação Alvo:** Atributos relacionados a dimensões celulares e irregularidades morfológicas possuem forte impacto. A variável worst concave points apresentou a maior correlação com o diagnóstico (**-0.79**). Note que a correlação é negativa, indicando que quanto maior o valor desse atributo, menor a chance de ser Benigno (Classe 1).
- **Identificação de Multicolinearidade:** O heatmap revela blocos de alta correlação (próximos a 1.0) entre medidas de Raio, Perímetro e Área. Isso indica redundância de informação, o que favorece o uso de modelos como Regressão Logística com penalização ou Random Forest.
- **Variabilidade de Escalas:** As estatísticas descritivas mostram variáveis com ordens de magnitude muito distintas (ex: 'mean area' na casa dos milhares vs 'smoothness' em decimais). Isso reforça a necessidade crítica de **Padronização (Z-score)** para não enviesar modelos baseados em distância.
- **Próximo Passo:** Visualizar a dispersão das variáveis chave e aplicar o pré-processamento.

Step 4.1: Distribuição das Variáveis (Pairplot)

Relação entre as Principais Variáveis Preditoras



- **Análise de Separabilidade:** O Pairplot revela que atributos como worst area e worst concave points apresentam clusters distintos para as classes Maligna (0) e Benigna (1). As curvas de densidade (KDE) na diagonal mostram que, embora haja separação, existe uma zona de sobreposição crítica onde o erro de diagnóstico é mais provável.
- **Complexidade das Fronteiras:** A relação entre as variáveis não é perfeitamente linear; observam-se padrões de dispersão que sugerem que um nódulo maligno pode apresentar características heterogêneas. Isso valida a necessidade de modelos que calculem margens de decisão multidimensionais.
- **Conclusão Técnica:** A detecção visual de *outliers* e zonas de intersecção justifica a estratégia de treinar modelos de *Ensemble* (como Random Forest) e modelos de margem máxima (SVM), capazes de capturar essas nuances sem sofrer com a alta correlação entre raio e perímetro.
- **Próximo Passo:** Avançar para a separação do dataset (Treino/Teste) e o pré-processamento (Padronização).


Step 5: Pré-processamento e Divisão

- **Estratégia de Amostragem:** O dataset foi segmentado em **455 amostras para Treinamento (80%)** e **114 para Teste (20%)**. A utilização do `stratify=y` garantiu que a proporção de casos malignos e benignos fosse idêntica em ambos os conjuntos, evitando um modelo tendencioso.
- **Mecânica de Padronização (Scaling):** Aplicamos o `StandardScaler` para converter todas as features para a mesma ordem de grandeza (média 0 e desvio padrão 1). Isso é vital para que atributos com valores numéricos altos (como 'area') não dominem o aprendizado sobre atributos com valores pequenos (como 'smoothness').
- **Integridade Analítica:** O escalonador foi ajustado (*fit*) exclusivamente nos dados de treino e apenas aplicado (*transform*) ao teste. Essa prática rigorosa previne o **Data Leakage** (vazamento de dados), assegurando que o desempenho reportado no teste seja uma estimativa realista para novos pacientes.
- **Próximo Passo:** Iniciar o treinamento simultâneo de múltiplos algoritmos para comparação de performance.

Step 6: Seleção do Modelo


- **Volume de Dados:** O conjunto de treinamento conta com **30 variáveis preditoras** padronizadas.
- **Justificativa de Escopo das Variáveis:** Optamos por utilizar **todas as variáveis** em vez de selecionar apenas as de maior correlação para garantir que o modelo não perca interações não lineares ou sinais sutis presentes nas features menos correlacionadas. A redundância (multicolinearidade) é tratada matematicamente pelos mecanismos de regularização L2 da Regressão Logística, que penaliza coeficientes excessivos sem descartar informação potencialmente útil.
- **Performance do Modelo Escolhido (Regressão Logística):**
 - **Acurácia:** 98.25%
 - **Recall (Sensibilidade):** 98.61%
 - **Precisão:** 98.61%
 - **F1-Score:** 98.61%
- **Justificativa Técnica (Logística vs SVM):** Embora ambos os modelos tenham apresentado métricas de performance idênticas neste dataset, a **Regressão Logística** foi selecionada como modelo final por critérios de robustez estatística e eficiência computacional:
 1. **Output Probabilístico:** Diferente do SVM, que foca na margem geométrica e gera previsões 'hard', a Regressão Logística é um modelo estatístico que estima diretamente a probabilidade logit. Isso permite calibrar o limiar de decisão (*threshold*) de forma mais flexível.
 2. **Convexidade e Estabilidade:** A função de perda da Logística (Log-Loss) é estritamente convexa, garantindo convergência global estável. O SVM, especialmente com kernels complexos, pode ser mais sensível a hiperparâmetros e ruídos, o que torna a Logística uma escolha mais parcimoniosa (Navalha de Ockham).
 3. **Custo Computacional:** A implementação da Regressão Logística possui complexidade linear em relação ao número de observações, sendo significativamente mais rápida para inferência e treinamento do que o SVM, que escala de forma quadrática.
- **Próximo Passo:** Analisar a Matriz de Confusão para verificar a distribuição dos erros residuais.

Step 7: Matriz de Confusão




- **Auditoria de Erros e Acertos:** A matriz de confusão quantifica o desempenho real do modelo em dados não vistos.
 - **Verdadeiros Negativos (Benignos Corretos):** 41
 - **Verdadeiros Positivos (Malignos Corretos):** 71
- **Análise de Falsos Negativos (Risco Crítico):** Identificamos **1** caso(s) onde o modelo previu 'Benigno' mas o paciente era 'Maligno'. Este é o erro mais custoso em oncologia (Erro Tipo II).
- **Análise de Falsos Positivos (Custo Operacional):** Ocorreram **1** caso(s) onde o modelo indicou 'Maligno' em um paciente 'Benigno' (Erro Tipo I), resultando em exames confirmatórios desnecessários.
- **Conclusão de Confiabilidade:** A predominância de acertos na diagonal principal valida a estabilidade estatística da fronteira de decisão da Regressão Logística.

Step 8: Explicabilidade e Biomarcadores



- **Decodificando a IA:** O modelo não toma decisões aleatórias. A análise de importância revela que a variável **worst texture** é o principal driver do diagnóstico. No contexto citológico, isso indica que a textura e as irregularidades no contorno do núcleo celular são indicadores estatísticos de maior peso para distinguir células malignas.
- **Biomarcadores Digitais:** Além da principal, variáveis como radius error (variação no tamanho) e worst concave points (severidade das deformidades) formam o tripé de decisão. Isso alinha o modelo ao raciocínio médico, onde a pleomorfia (variação de forma/tamanho) é um sinal clássico de malignidade.



- **Transparência com SHAP:** Utilizamos os Valores de Shapley para garantir que cada predição individual possa ser explicada. O gráfico SHAP mostra não apenas *quais* variáveis importam, mas se elas estão empurrando o diagnóstico para 'Maligno' ou 'Benigno'.
- **Conclusão Técnica:** A convergência entre a importância nativa do modelo e os valores SHAP elimina o efeito 'caixa-preta', permitindo que o oncologista valide a lógica matemática com base em evidências biológicas visíveis nos dados.
- **Próximo Passo:** Analisar como essa inteligência se traduz em benefícios reais e éticos na rotina hospitalar.

Step 9: Discussão Crítica para a Prática Médica

A aplicação de modelos preditivos na saúde exige cuidados éticos e técnicos estritos. O modelo desenvolvido atua como um sistema CAD/CDSS (*Computer-Aided Diagnosis*), não substituindo o patologista humano, mas operando como uma robusta "segunda opinião" automatizada.

- **Triagem e Priorização (Triage):** O algoritmo analisa os dados primeiro. Casos com alta probabilidade de malignidade recebem um marcador (*flag*) urgente, indo para o topo da fila de laudos, acelerando diagnósticos e tratamentos críticos.
- **Dupla Checagem de Segurança:** O médico confronta seu laudo visual com o do sistema. Divergências funcionam como um gatilho de alerta para reavaliação sob o microscópio, reduzindo erros diagnósticos causados por fadiga visual humana.
- **Impacto no Mundo Real:** Na oncologia, um Falso Negativo (dizer que é benigno quando é câncer) é o cenário mais perigoso. A otimização focada em maximizar o **Recall (Sensibilidade)** é a abordagem médica mais garantida.
- **Papel do Médico e Explicabilidade:** A IA não dita regras cegamente. A auditabilidade via SHAP "traduz" a decisão da máquina (ex: *"risco elevado devido a medidas extremas de área e pontos côncavos"*), permitindo que o profissional valide a lógica matemática e mantenha absoluta autoridade clínica.
- **Próximo Passo:** Exportar o pipeline final (modelo e scaler) para integração em softwares hospitalares.

Step 10: Persistência e Portabilidade

- **Consolidação dos Artefatos:** O pipeline completo foi desacoplado do ambiente de desenvolvimento e persistido nos arquivos `modelo_breast_cancer.pkl` (inteligência do modelo) e `scaler_breast_cancer.pkl` (parâmetros de normalização).
- **Prevenção de Inconsistências:** A exportação do scaler é tão crítica quanto a do modelo. Em produção, novos dados brutos devem ser processados exatamente com a mesma média e desvio padrão calculados no treinamento para evitar distorções nas previsões.
- **Prontidão para Deploy (CI/CD):** Com estes arquivos, o sistema está pronto para ser integrado a contêineres Docker ou serviços em nuvem (como AWS Lambda ou Google Cloud Run). O modelo pode agora processar novos diagnósticos em milissegundos sem a necessidade de reprocessar a base histórica.
- **Conclusão Técnica:** O projeto encerra o ciclo de vida de desenvolvimento (Model Development) e entra na fase de entrega de valor (Model Serving), garantindo reprodutibilidade e escalabilidade.
- **Status Final do Projeto:** Entregável técnico concluído com sucesso! ■