

■ Relatório Técnico de Machine Learning — Diagnóstico Tabular

Projeto: Breast Cancer Wisconsin | Aluno: Gustavo Luis dos Santos


■ ACESSO AO REPOSITÓRIO & RECURSOS:

- GitHub do Projeto: <https://github.com/gustavobhm/fiap-tech-challenge-fase1>
- Notebook Processado: notebooks/01_classificacao_tabular_wisconsin_V11.ipynb
- Vídeo de Demonstração: [COLOQUE SEU LINK DO YOUTUBE AQUI](#)

1. Discussões da Análise Exploratória (EDA)


A análise baseia-se em 569 amostras clínicas, divididas entre 357 casos Benignos e 212 Malignos. A avaliação da distribuição das variáveis preditoras permite compreender a separabilidade das classes.

Relação entre as Principais Variáveis Preditoras



Discussão do Pairplot: Observa-se que características espaciais e dimensionais das células apresentam boa capacidade de discriminação entre as classes, formando agrupamentos distinguíveis entre tumores benignos e malignos.

Matriz de Correlação das Variáveis Médicas



Discussão da Matriz de Correlação: A matriz revela alta multicolinearidade entre variáveis de dimensão (por exemplo, mean radius, mean perimeter e mean area apresentam coeficientes próximos a 1.0). Esta redundância orienta a necessidade de algoritmos robustos a features colineares, como modelos baseados em penalização (Regressão Logística) ou ensembles de árvores.

2. Estratégias de Pré-processamento

Para garantir a integridade da validação e o desempenho do modelo, as seguintes estratégias foram aplicadas:

- **Divisão Estratificada (Train/Test Split):** Separação de 80% dos dados para treinamento e 20% para teste, mantendo a proporção original das classes para evitar viés preditivo.
- **Padronização e Prevenção de Data Leakage:** Utilizou-se o StandardScaler para normalizar a escala das features. O transformador foi ajustado (fit) estritamente nos dados de treino e apenas aplicado (transform) ao conjunto de teste, garantindo a ausência de vazamento de dados.

3. Modelos Usados e Justificativa

Foram selecionados 6 algoritmos de diferentes naturezas matemáticas para avaliar qual melhor mapeia as nuances do dataset oncológico:


1. **Regressão Logística e SVM:** Avaliam a separabilidade linear em espaços de alta dimensão.
2. **Decision Tree, Random Forest e Gradient Boosting:** Modelos baseados em regras de decisão e ensemble, escolhidos por sua robustez contra multicolinearidade e outliers.
3. **KNN:** Avalia a classificação por similaridade espacial de instâncias vizinhas.

4. Resultados e Interpretação dos Dados

Em contextos de rastreamento oncológico, a métrica **Recall para a classe Maligna (0)** é o indicador crítico, pois minimiza a ocorrência de Falsos Negativos. A **Regressão Logística** obteve a melhor performance consolidada.


Modelo Avaliado	Acurácia	Recall (Maligno)	Precision	F1-Score
Regressão Logística	98.25%	97.62%	98.81%	98.21%
SVM (Kernel RBF)	98.25%	97.62%	98.81%	98.21%
Gradient Boosting	95.61%	90.48%	97.44%	93.83%
Random Forest	95.61%	92.86%	95.12%	93.98%
KNN (K=5)	95.61%	92.86%	95.12%	93.98%
Decision Tree	91.23%	92.86%	84.78%	88.64%


Métrica	Precision	Recall	F1-Score	Support
Maligno (0)	0.98	0.98	0.98	42
Benigno (1)	0.99	0.99	0.99	72
Acurácia Global			0.98	114



Interpretação: O modelo otimizado demonstrou extrema precisão diagnóstica, com apenas 1 Falso Positivo e 1 Falso Negativo sobre as instâncias de teste, validando o pipeline adotado.

5. Explicabilidade Matemática e Atributos de Maior Impacto





Interpretação do SHAP: A análise por Valores de Shapley (SHAP) garante a auditabilidade e transparência do modelo. O gráfico demonstra que medições elevadas de anomalias celulares (pontos em vermelho) — com destaque para textura (worst texture), erro dimensional (radius error) e deformidades (worst concave points) — geram impactos SHAP negativos. Como a codificação do dataset define a **Classe 0 como Maligno**, esses valores altos atuam como os *drivers* primários para impulsionar a predição para o diagnóstico de câncer, alinhando a IA ao raciocínio clínico tradicional.

6. Discussão Crítica: O Modelo na Prática Médica

A aplicação de modelos preditivos na saúde feminina exige cuidados éticos e técnicos estritos. Respondendo aos requisitos do projeto:

- **O modelo pode ser utilizado na prática?** Sim, mas exclusivamente operando como um **Sistema de Apoio à Decisão Clínica (CDSS - Clinical Decision Support System)**. Em nenhuma hipótese ele substitui o diagnóstico final de um patologista humano.
- **Triagem e Priorização (Triage):** Em hospitais com alto volume de exames de biópsia, o algoritmo pode atuar no primeiro rastreio. Casos apontados com alta probabilidade de malignidade recebem uma sinalização urgente (flag), indo para o topo da fila de laudos do médico, acelerando diagnósticos precoces.
- **Dupla Checagem (Second Opinion):** O médico emite o laudo e confronta com o sistema. Divergências funcionam como um gatilho de segurança para reavaliação.
- **Papel do Médico e Explicabilidade:** O SHAP permite que o médico entenda o 'porquê' da decisão da IA (ex: risco elevado devido a pontos côncavos severos), mantendo a autoridade e responsabilidade clínica do profissional.

7. Exportação e Prontidão para Produção (Deploy)

O pipeline completo de inferência foi exportado para os arquivos `modelo_breast_cancer.pkl` e `scaler_breast_cancer.pkl`. Os artefatos estão prontos para integração em APIs REST hospitalares, garantindo previsões rápidas em tempo real.